

The background is a vibrant red with a textured, slightly grainy appearance. It features several stylized black and white film strips that curve across the frame. Two large, yellow film reels are positioned on the left and right sides, each with four circular holes showing a black and white striped pattern. A white rectangular box with a black border is centered in the middle of the image, containing the main title and authors. A small white tag with a black border is attached to the top of this box.

Proyecto 2:



Clasificación de géneros cinematográficos

Luis Alejandro Garzón Ramirez
Zorayda Acevedo Jimenez
Yulieth Danitza Aguillón Ortega

12 abril 2025



Contenido

- 01** Entendimiento de la situación
- 02** Objetivo de negocio y minería de datos
- 03** Entendimiento de los datos
- 04** Preparación de los datos
- 05** Modelo
- 06** Evaluación

01. Entendimiento de la situación


Cine



El cine es una forma de contar historias, y al igual que en la literatura.

Los géneros cinematográficos ayudan a clasificar las películas según su contenido y trama

Generos más representativos



- Acción
- Aventura
- Catostrofe
- Ciencia ficcion
- Comedia
- Documental
- Drama
- Fantasia
- Suspenso
- Musical
- Terror

Importancia de los generos



Guían al espectador

Estructuran la narrativa

Facilitan la comercialización

Favorecen la evolución del cine

Definen la experiencia/emocion


Estructuran el cine

Enriquecen la manera en que se cuentan y experimentan las historias.



Uso de modelos de procesamiento de texto para clasificacion de generos de peliculas = brindar una mejor experiencia al cliente.
Evitando la clasificacion manual (< error)

02. Objetivo de negocio y minería de datos



Objetivos de negocio

Optimizar la clasificación de películas por género para mejorar la experiencia del usuario y la eficiencia en la categorización de contenido.

Medido a través de: % de películas cuyo género fue corregido manualmente por usuarios o editores después de la clasificación automática.



Objetivos de minería de datos

Diseñar un modelo de Procesamiento del Lenguaje Natural (NLP) para predecir la probabilidad de que la película pertenezca al género cinematográfico correcto, con un **AUC $\geq$ 0.89**.

03. Entendimiento de los datos



Datos entregados

El conjunto de entrenamiento contiene 7,895 observaciones, mientras que el de prueba cuenta con 3,383.



Nombre columna	Descripción	Training	Test
<u>Index</u>	Identificador del campo	x	x
<u>Year</u>	Año de lanzamiento de la película	x	x
<u>Title</u>	Título de la película	x	x
<u>Plot</u>	Descripción de la película	x	x
<u>Genres</u>	Genero al cual pertenece la película (campo <u>target</u>)	x	-
<u>Rating</u>	Calificación de la película	x	-




Observaciones

- ★ 24 géneros de películas
- ★ Existen aproximadamente 6900 películas clasificadas en varios géneros. la mayoría entre 3 y 4 géneros
- ★ Cantidad de palabras por reseña (campo plot) en la mayoría oscila en un rango de 200 a 250 palabras.


★ 04. Preparación de los datos ★




Se define el idioma en inglés



Se convierten a minúsculas todas las palabras del campo "plot",



Se eliminan palabras vacías y signos de puntuación



Se tokenizan y lematizan las palabras con el fin de capturar mejor la estructura gramatical

Estátegias de vectorización

- 1 **CountVectorizer** genera una matriz de ocurrencias basada en el conteo de palabras de acuerdo a la cantidad de veces que aparecen en el documento.
- 2 **TfidfVectorizer** ajusta ese conteo mediante el cálculo del TF-IDF (Term Frequency - Inverse Document Frequency), el cual consiste en ponderar la importancia de cada término en función de su frecuencia de aparición en el documento completo.

05. Modelos

1 Regresión logística

Preprocesado	Parámetros resultantes	AUC en Test
CountVectorized ngram_range=(1, 3)	'C': 0.042768212125502, 'solver': 'newton-cg', 'max_iter': 306	0.8622
Tf-idf	'C': 1.5485521740699046, 'solver': 'lbfgs', 'max_iter': 213	0.8708
Universal Sentence Encoder	'C': 0.7624219947489701, 'solver': 'newton-cg', 'max_iter': 265	0.8939

2 Random Forest

Preprocesado	Parámetros resultantes	AUC en Test
CountVectorized ngram_range=(1, 3)	'n_estimators': 164, 'max_depth': 14, 'min_samples_split': 9, 'min_samples_leaf': 4, 'max_features': 'sqrt'	0.8186
Tf-idf	'n_estimators': 160, 'max_depth': 20, 'min_samples_split': 8, 'min_samples_leaf': 6, 'max_features': 'sqrt'	0.8320
Universal Sentence Encoder	'n_estimators': 199, 'max_depth': 14, 'min_samples_split': 6, 'min_samples_leaf': 9, 'max_features': 'sqrt'	0.8622

3 XBoost

Preprocesado	Parámetros resultantes	AUC en Test
CountVectorized ngram_range=(1, 3)	'n_estimators': 90, 'max_depth': 7, 'learning_rate': 0.11625302168743173	0.8335
Tf-idf	'n_estimators': 101, 'max_depth': 7, 'learning_rate': 0.09149064675943756	0.8228
Universal Sentence Encoder	'n_estimators': 158, 'max_depth': 9, 'learning_rate': 0.1559513664628433	0.8790

06. Evaluación



AUC	<u>Regresion logistica</u>	<u>Random forest</u>	<u>XGBoost</u>
<u>CountVectorized</u> <u>ngram_range=(1, 3)</u>	0.8620	0.8278	0.8441
<u>Tf-idf</u>	0.8744	0.8341	0.8286
<u>Universal Sentence</u> <u>Encoder</u>	★ 0.8908	0.8464	0.8670



Vemos que el Embedding Universal Sentence Encoder junto con el modelo de regresión logística son los que logran la metrica objetivo.



Este algoritmo es ideal predecir los géneros de las películas basadas en la trama de la misma, logrando así una mejor experiencia al usuario reteniéndolo por más tiempo. [💰]





Gracias