

Proyecto 2 - Tópicos avanzados en analítica

Clasificación de géneros cinematográficos usando la metodología CRISP-DM

Luis Alejandro Garzón Ramírez

Zorayda Acevedo Jiménez

Yulieth Danitza Aguillón Ortega

1. Entendimiento de la situación

El cine es una forma de contar historias, y al igual que en la literatura, los géneros cinematográficos ayudan a clasificar las películas según su contenido y trama. De acuerdo con Pablo Argañarás, (2024) con el paso del tiempo, estos géneros han evolucionado, y aunque existe una clasificación general aceptada, los avances tecnológicos y sociales han permitido su expansión y fusión, dando lugar a una amplia variedad de subgéneros. La evolución de la sociedad y el tiempo han hecho que hoy podamos identificar distintos géneros cinematográficos según diversos criterios, como el estilo, la audiencia o la ambientación. Factores como el ritmo, el tono, la intención de evocar ciertas emociones, el entorno o incluso el formato de la película, son clave para definir su género. Sin embargo, no hay una clasificación rígida, ya que los géneros han ido adquiriendo una identidad híbrida a lo largo de la historia, especialmente desde la Segunda Guerra Mundial. A continuación, exploramos los géneros más representativos del cine:

- **Acción:** Películas llenas de adrenalina, con acrobacias, persecuciones, rescates y batallas que mantienen al espectador al borde del asiento.
- **Aventura:** Aunque pueden parecerse a las de acción, estas películas se centran en nuevas experiencias, exploraciones y viajes a lugares exóticos con un ritmo más constante.
- **Catástrofe:** Como su nombre lo indica, giran en torno a desastres naturales o tragedias. Suelen contar con un elenco amplio y generan tensión al mantener la incertidumbre sobre el desenlace.
- **Ciencia ficción:** Historias especulativas basadas en fenómenos científicos reales o imaginarios, muchas veces utilizadas para hacer críticas sociales o políticas.
- **Comedia:** Películas diseñadas para hacer reír y ofrecer un escape de la realidad, con un tono alegre y situaciones humorísticas.
- **Documental:** Relatos basados en hechos reales que, a través de imágenes, sonidos y videos, buscan acercar al espectador a diversas realidades sociales o personales.
- **Drama:** Basado en conflictos entre personajes, con escenarios y temáticas más serias. Es uno de los géneros más amplios y diversos del cine.
- **Fantasía:** Similar a la ciencia ficción, pero con elementos mágicos o sobrenaturales. Sus protagonistas pueden tener poderes o ser personajes completamente irreales.
- **Musical:** Películas donde la historia se complementa con fragmentos musicales que, aunque a veces no tienen relación directa con la trama, buscan impactar al público.
- **Suspense:** Historias de intriga y tensión, donde la acción y el misterio mantienen en vilo al espectador, con héroes y villanos que juegan un papel clave.

- **Terror:** Diseñado para provocar miedo, angustia o incomodidad, a menudo inspirado en leyendas, mitos o relatos literarios de horror.

Los anteriores son solo algunos de los géneros más importantes del cine, cada uno con sus propias características y formas de emocionar al público. Los géneros en las películas son fundamentales porque ayudan a clasificar y organizar las producciones cinematográficas según su estilo, contenido y tono. Su importancia radica en varios aspectos clave:

- **Guían al espectador:** Permiten a la audiencia elegir películas según sus gustos y expectativas, facilitando la selección de contenidos afines a sus preferencias.
- **Estructuran la narrativa:** Cada género tiene convenciones y reglas que establecen cómo se desarrollan las historias, ayudando a los cineastas a construir tramas coherentes y atractivas.
- **Facilitan la comercialización:** Los géneros son utilizados en la promoción de películas, lo que ayuda a los estudios y distribuidores a atraer al público adecuado.
- **Favorecen la evolución del cine:** A lo largo del tiempo, los géneros han evolucionado y se han mezclado, dando lugar a nuevas formas narrativas y enfoques innovadores en la cinematografía.
- **Definen la experiencia emocional:** Dependiendo del género, una película puede generar miedo, emoción, risas o reflexión, creando una conexión emocional con el público.

En definitiva, los géneros cinematográficos son una herramienta esencial tanto para creadores como para espectadores, ya que estructuran el cine y enriquecen la manera en que se cuentan y experimentan las historias. Lo anterior, resalta la importancia del porque un modelo analítico puede apoyar en predecir géneros cinematográficos, ya que permite en la industria, mejorar la organización del contenido, obtener más visualizaciones, recomendación a los clientes y establecer estrategias de marketing segmentadas, además de ser una herramienta valiosa para creadores del contenido a la hora de decidir el contenido a impulsar o producir en las plataformas donde se observar producciones cinematográficas.

2. Objetivos de negocio

Optimizar la clasificación de películas por género para mejorar la experiencia del usuario y la eficiencia en la categorización de contenido. Medido a través de: % de películas cuyo género fue corregido manualmente por usuarios o editores después de la clasificación automática.

3. Objetivos de minería de datos

Diseñar un modelo de Procesamiento del Lenguaje Natural (NLP) para predecir la probabilidad de que la película pertenezca al género cinematográfico correcto, con un AUC ≥ 0.89 .

4. Entendimiento de los datos

Se entrega una base de datos de entrenamiento y pruebas con el fin de calcular la probabilidad de que la película pertenezca a algún género cinematográfico. Se dispone de dos conjuntos de datos: uno de entrenamiento y otro de prueba. El conjunto de entrenamiento contiene 7,895 observaciones, mientras que el de prueba cuenta con 3,383. Ambos conjuntos incluyen cinco columnas que proporcionan información clave sobre cada película: el año de lanzamiento, el título en formato de texto, una descripción de la trama, la lista de géneros asociados y la calificación de la película, representada como un valor numérico de tipo flotante.

Tabla 1. Datos de entrenamiento

dataTraining.head()					
	year	title	plot	genres	rating
3107	2003	Most	most is the story of a single father who takes...	['Short', 'Drama']	8.0
900	2008	How to Be a Serial Killer	a serial killer decides to teach the secrets o...	['Comedy', 'Crime', 'Horror']	5.6
6724	1941	A Woman's Face	in sweden , a female blackmailer with a disfi...	['Drama', 'Film-Noir', 'Thriller']	7.2
4704	1954	Executive Suite	in a friday afternoon in new york , the presi...	['Drama']	7.4
2582	1990	Narrow Margin	in los angeles , the editor of a publishing h...	['Action', 'Crime', 'Thriller']	6.6




Tabla 2. Datos de pruebas

dataTesting.head()			
	year	title	plot
1	1999	Message in a Bottle	who meets by fate , shall be sealed by fate
4	1978	Midnight Express	the true story of billy hayes , an american c...
5	1996	Primal Fear	martin vail left the chicago da ' s office to ...
6	1950	Crisis	husband and wife americans dr . eugene and mr...
7	1959	The Tingler	the coroner and scientist dr . warren chapin ...

Nombre columna	Descripción	Training	Test
Index	Identificador del campo	X	X
Year	Año de lanzamiento de la película	X	X
Title	Título de la película	X	X
Plot	Descripción de la película	X	X
Genres	Genero al cual pertenece la película (campo target)	X	-
Rating	Calificación de la película	X	-

Tabla 3. Descripción de las columnas de los datasets de entrenamiento y pruebas

Se verifica la información descriptiva del dataset de training, encontrando que se clasifican 24 géneros de películas, que existen aproximadamente 6900 películas clasificadas en varios géneros la mayoría entre 3 y 4 géneros, la cantidad de palabras por reseña (campo plot) en la mayoría oscila en un rango de 200 a 250 palabras.



5. Preparación de los datos

Se realiza la preparación de los datos del dataset de entrenamiento, donde a través de la creación de una función de preprocesamiento de texto y con diferentes funciones de la librería `nltk`, se define el idioma en inglés, se convierten a minúsculas todas las palabras del campo “plot”, se eliminan palabras vacías y signos de puntuación (con la función “`stop_words`”), se tokenizan (con la función “`tokenizer`”) y por último se lematizan las palabras con el fin de capturar mejor la estructura gramatical y el contexto, para lo cual se utilizó la función “`lemmatizer`” junto con la función “`pos_tag`” la cual añade etiquetas POS que indican si la palabra analizada es una preposición, sustantivo, nombre, verbo, adjetivo ó adverbio.

Realizado lo anterior se logra obtener una depuración y limpieza de los datos como se muestra un ejemplo a continuación:

Reseña Original: *during world war ii south sea beachcomber walter eckland is persuaded to spy on planes passing over his island . he gets more than he bargained for as schoolteacher catherine frenau arrives on the run from the japanese with her pupils in tow!*

Lematización: world war ii south sea beachcomber walter eckland persuade spy plane pass island get bargain schoolteacher catherine frenau arrives run japanese pupil tow

5.1 Estrategias de Vectorización:

Después de realizar las tareas básicas de limpieza y preparación de los datos, se procedió a la vectorización del conjunto de entrenamiento utilizando las herramientas de Scikit-Learn, específicamente **CountVectorizer** y **TfidfVectorizer**.

- CountVectorizer genera una matriz de ocurrencias basada en el conteo de palabras de acuerdo a la cantidad de veces que aparecen en el documento, mientras que
- TfidfVectorizer ajusta ese conteo mediante el cálculo del **TF-IDF (Term Frequency - Inverse Document Frequency)**, el cual consiste en ponderar la importancia de cada término en función de su frecuencia de aparición en el documento completo.

El objetivo fue comparar el rendimiento de estos esquemas de representación con distintos algoritmos de clasificación: **Random Forest**, **Regresión Logística** y **XGBoost**, con el fin de predecir el **género de las películas** a partir de su sinopsis representada en el campo “plot” del dataset.

Posteriormente, se implementó una técnica más avanzada de representación semántica utilizando el **Universal Sentence Encoder (USE)** de Google, un modelo preentrenado que convierte cada frase en un vector denso de **512 dimensiones**. A diferencia de CountVectorizer y TfidfVectorizer, que trabajan a nivel de palabras individuales sin considerar el orden ni el contexto, **USE captura el significado contextual completo de la frase**, permitiendo una representación más amplia y adecuada para tareas de comprensión semántica.

Esta vectorización se combinó nuevamente con los tres clasificadores mencionados, observándose el mejor desempeño en términos de **accuracy** al utilizar el modelo de **Regresión Logística** junto con los embeddings generados por USE.

6. Modelos

En cuanto a los modelos utilizados, nos centramos en tres enfoques principales. En primer lugar, empleamos un modelo básico pero robusto, como la regresión logística. A continuación, incorporamos un modelo más complejo, el Random Forest, y finalmente, utilizamos XGBoost, un algoritmo basado en boosting que ha demostrado ser altamente efectivo. Para optimizar el rendimiento de cada modelo, se empleó la librería Optuna. Además, cada uno de los modelos fue evaluado utilizando los tres enfoques de preprocesamiento de texto mencionados anteriormente: CountVectorizer con un rango de n-gramas de (1, 3), TF-IDF y Universal Sentence Encoder.

Es relevante a mencionar es que en todos los modelos se hace uso de la función OneVsRestClassifier la cual es pertinente en problemas de clasificación multiclase donde cada individuo (en este caso películas) pueden pertenecer a más de una clase a la vez (en este caso géneros), esto gracias a que entrena un clasificador binario para cada clase individual de manera independiente.

A continuación, se explica cada modelo y se presentan sus resultados en el conjunto de prueba,

Regresión logística:

Este modelo permite realizar clasificación binaria mediante la predicción de la probabilidad de que, dado un conjunto de valores de entrada (en este caso vectores), cada individuo

pertenezca o no a una clase específica. Aunque está diseñado para clasificar una sola clase, la función OneVsRestClassifier posibilita su adaptación a problemas multiclase, entrenando un modelo independiente para cada uno de los 24 géneros posibles.

Después de la optimización los parámetros resultantes para cada uno de los preprocesados y sus respectivos resultados en test fueron:

Preprocesado	Parámetros resultantes	AUC en Test
CountVectorized ngram_range=(1, 3)	'C': 0.042768212125502, 'solver': 'newton-cg', 'max_iter': 306	0.8622
Tf-idf	'C': 1.5485521740699046, 'solver': 'lbfgs', 'max_iter': 213	0.8708
Universal Sentence Encoder	'C': 0.7624219947489701, 'solver': 'newton-cg', 'max_iter': 265	0.8939

Random forest:

El Random Forest es un modelo más complejo basado en el enfoque de conjuntos (ensemble learning), que emplea múltiples árboles de decisión para realizar predicciones. Al entrenar cada árbol con diferentes subconjuntos aleatorios de los datos, este método reduce la probabilidad de sobreajuste (overfitting), mejorando así la robustez y generalización del modelo. La combinación de los resultados de los múltiples árboles contribuye a una mayor estabilidad y precisión en las predicciones.

Se muestran los resultados:

Preprocesado	Parámetros resultantes	AUC en Test
CountVectorized ngram_range=(1, 3)	'n_estimators': 164, 'max_depth': 14, 'min_samples_split': 9, 'min_samples_leaf': 4, 'max_features': 'sqrt'	0.8186
Tf-idf	'n_estimators': 160, 'max_depth': 20, 'min_samples_split': 8, 'min_samples_leaf': 6, 'max_features': 'sqrt'	0.8320
Universal Sentence Encoder	'n_estimators': 199, 'max_depth': 14, 'min_samples_split': 6, 'min_samples_leaf': 9, 'max_features': 'sqrt'	0.8622

XGBoost:

Es un algoritmo que se enfoca en la unión de modelos débiles para hacer uno fuerte, usualmente usa arboles de decisión, pero a diferencia de Random Forest, que entrena árboles de manera independiente, XGBoost entrena árboles de forma secuencial, donde cada árbol trata de corregir los errores del árbol anterior, para evitar que este proceso genere overffiting

se controla que la profundidad máxima de los árboles y la tasa de aprendizaje este en valores pequeños.

Se muestran los resultados:

Preprocesado	Parámetros resultantes	AUC en Test
CountVectorized ngram_range=(1, 3)	'n_estimators': 90, 'max_depth': 7, 'learning_rate': 0.11625302168743173	0.8335
Tf-idf	'n_estimators': 101, 'max_depth': 7, 'learning_rate': 0.09149064675943756	0.8228
Universal Sentence Encoder	'n_estimators': 158, 'max_depth': 9, 'learning_rate': 0.1559513664628433	0.8790

7. Evaluación

Finalmente, comparando los distintos modelos con cada técnica de manejo (vectorización) de datos tenemos la siguiente matriz,

AUC	Regresión logística	Random forest	XGBoost
CountVectorized ngram_range=(1, 3)	0.8620	0.8278	0.8441
Tf-idf	0.8744	0.8341	0.8286
Universal Sentence Encoder	0.8908	0.8464	0.8670

Vemos que el Embedding Universal Sentence Encoder junto con el modelo de regresión logística son los que logran la mejor métrica en test, consiguiendo también el AUC objetivo de 0,89; con esto se tiene un algoritmo confiable para predecir los géneros de las películas basadas en la trama de esta, logrando así una mejor experiencia al usuario reteniéndolo por más tiempo y optimizando el trabajo interno ya que se reduce la necesidad de corregir generos de películas de manera manual, en resumen se consigue una mejor experiencia de cliente y menor costo operacional optimizando así dos procesos clave a nivel compañía.

Referencias

Argañarás, P. Exclusiva. (2024). Los géneros cinematográficos: Orígenes, evolución y adaptaciones. Exclusiva. <https://exclusiva.com.ar/espectaculo/los-generos-cinematograficos-origenes-evolucion-y-adaptaciones/>