





Proyecto 3


Modelos de grafos para la base TWITCH

(DE)




-Luis Alejandro Garzón Ramirez
-Zorayda Acevedo Jimenez
-Yulieth Danitza Aguillón Ortega

Mayo 2025




Contenido



- 1 Entendimiento de la situación
- 2 Objetivo de negocio y minería de datos
- 3 Entendimiento de los datos
- 4 Preparación de los datos
- 5 Modelo
- 6 Evaluación



1 Entendimiento de la situación



Entretenimiento digital

2 Objetivo de negocio y minería de datos



Objetivo de negocio

Identificar de forma anticipada a los **usuarios que probablemente transmitan contenido para adultos**, con el fin de fortalecer los mecanismos de reporte temprano, para proteger la comunidad y asegurar el cumplimiento de las políticas de la plataforma.

$$KPI = \frac{\text{Total de usuarios predichos como transmisores de contenido para adultos}}{\text{Usuarios correctamente identificados como transmisores de contenido para adultos}} \times 100$$

Objetivo minería de datos


Generar un modelo de clasificación que permita obtener los siguientes valores de métricas en el conjunto de datos de test:

- Precisión clase objetivo > 0,8
- Recall clase objetivo > 0,8


3 Entendimiento de los datos



Observaciones




- El conjunto de datos contiene **un solo grafo, compuesto por:**
 - Número de nodos: 9,498
 - Número de características por nodo: 128
 - Número de clases: 2 (este caso publica o no contenido para adultos)
- En cuanto a la **estructura del grafo**, se observa lo siguiente:
 - Las aristas no son dirigidas → las conexiones entre nodos son bidireccionales.
 - El grafo no contiene nodos aislados → todos los nodos están conectados al menos a otro nodo.
 - El grafo sí contiene bucles → algunos nodos están conectados consigo mismos.
- Distribución de clases** - Hay dos tipos de nodos en el grafo.
 - Clase 0 tiene 3756 nodos.
 - Clase 1 tiene 5742 nodos.Esto significa que hay más nodos de la clase 1 que de la clase 0.



Eficiencia Global → **0,38** red fragmentada o mal conectada + muchos nodos están lejanos o incluso desconectados.

4 Preparación de los datos






Normalización

NormalizeFeatures:

```
Min value: 0.0000  
Max value: 0.1006  
Mean: 0.0078  
Norma promedio: 0.1265
```

Normalización Manual:

```
Min value: 0.0000  
Max value: 0.6859  
Mean: 0.0620  
Norma promedio: 1.0000
```



```
Nodos de entrenamiento: 6648  
Nodos de validación: 950  
Nodos de prueba: 1900
```

5 Modelos



Modelo 1 - GNN Matriz Adyacencia

Modelo 3 - GAT Attention


Modelo 2 - GCN convolucional

hiperparámetro	Valor
Número de unidades oculta	32
Tasa de aprendizaje	0.01
Weight decay	0.0005
Función de perdida	CrossEntropyLoss
Número de épocas	150

Nombre Hiperparámetro	Comentario
hidden_channels=16	Número de neuronas en la capa oculta
lr=0.01	Tasa de aprendizaje del optimizador Adam
weight_decay=5e-4	Regularización L2 (evita sobreajuste)
dropout p=0.5	Probabilidad de "apagar" neuronas (solo en entrenamiento)
BCEWithLogitsLoss()	Función de pérdida usada
epochs=200	Número de épocas de entrenamiento
optimizer = Adam	Optimizador usado
threshold = 0.5 implícito en probs >= 0.5	Umbral de decisión para clasificación

Hiperparámetro	Valor
dim_h	120
heads	6
dropout	0.45
activación	ELU
epochs	500
learning_rate (lr)	0.0001361
weight_decay	0.00001
pos_weight	0.66
umbral de decisión	0.45
criterio de pérdida	BCEWithLogitsLoss

6 Evaluación



Modelo GNN	AUC	Accuracy	Precision		Recall	
			0	1	0	1
Modelo 0 - Nodes with features	0,49	0,61	0	0,61	0	1
Modelo 1 - Matriz de adyacencia	0,72	0,67	0,62	0,68	0,39	0,85
Modelo 2 - Convolutacional	0,72	0,66	0,62	0,67	0,39	0,87
Modelo 3 - Attention	0,72	0,68	0,62	0,71	0,50	0,80



Recomendaciones

¡Gracias!